

# INFERÊNCIA CAUSAL COM MACHINE LEARNING

uma aplicação para evasão fiscal

---

Rafael Felipe Bressan

2021-03-14

Receita Federal do Brasil

# Motivação

---

# Causalidade

- Limite de velocidade reduz as mortes no trânsito?
- Permissão para cobrança de bagagem aérea reduziu o preço das tarifas?
- O recebimento de uma carta-cobrança da Receita Federal faz com que o contribuinte recolha seus impostos devidos?
- Essas questões são **causais** em sua natureza. Requerem conhecimento do processo de geração dos dados. Suas respostas não podem ser calculadas apenas com os dados observados.

- Análise causal requer manipulação/intervenção no processo gerador
- Uma quebra estrutural é induzida
- Correlações anteriores não são mais válidas
- Dados puramente observacionais não carregam toda a informação necessária

$$Y_i = f(X_i, \epsilon_i; \theta)$$

- Causalidade requer inferência sobre parâmetros da distribuição,  $\theta$ 
  - *Machine Learning* tradicional oferece correlações a partir de dados observacionais
  - Inferência  $\neq$  previsão
    - ML: minimiza  $\hat{e} = \hat{y} - Y$
    - Análise causal: estima  $\hat{\theta}$  com intervalo de confiança
  - Boa previsão **não garante** correta estimação de parâmetros
  - **Viés de regularização:**  $\hat{f}_1(\cdot; \hat{\theta}_1) \approx \hat{f}_2(\cdot; \hat{\theta}_2)$  mesmo se  $\hat{\theta}_1 \neq \hat{\theta}_2$

- Como fazer com que algoritmos de ML façam estimação causal não-viesada?
- Fronteira do conhecimento em inferência causal
  - Chernozhukov et al. (2018) - *Double Machine Learning*
  - Wager and Athey (2018) - *Causal Forests*
  - Syrgkanis et al. (2019) - *Doubly Robust Instrumental Variables*

# Experimento Randomizado

---

# Experimento Randomizado

- Experimentos randomizados são o padrão-ouro para inferência causal
- Re-analisaremos o trabalho de Fellner, Sausgruber, and Traxler (2013)
- Correspondências fiscais para mais de 50.000 contribuintes
- Analisar efeitos de variação no conteúdo
  - Valores médios por tipo de carta
  - Heterogeneidade nos efeitos



## Descrição do Experimento

Tratamento	Descrição	Observações	Proporção
T0	Sem Correio	2586	0.0512099
T1	Correio	7984	0.1581053
T2	Ameaça	7821	0.1548774
T3	Info	7998	0.1583825
T4	Info&Ameaça	8101	0.1604222
T5	Moral	8084	0.1600855
T6	Moral&Ameaça	7924	0.1569171

# Problema de Atrito

- Atrito: contribuintes que deveriam receber a correspondência mas não foram encontrados
- Pode comprometer a aleatorização do experimento e **gerar viés** na inferência

Tratamento	Descrição	Cartas	Não Entregues	Taxa Atrito
T1	Correio	7984	1126	0.1410
T2	Ameaça	7821	1127	0.1441
T3	Info	7998	1173	0.1467
T4	Info&Ameaça	8101	1141	0.1408
T5	Moral	8084	1164	0.1440
T6	Moral&Ameaça	7924	1174	0.1482

# Análise Exploratória

- Uma boa aleatorização implica em balanceamento das covariadas (*features*) entre os tratamentos

Tratamento	Descrição	Gênero	Idade	Renda	População	Dens. pop.	Compliance
To	Sem Correio	0.6458	48.0170	20928.4068	45815.2715	8.1711	0.9355
T1	Correio	0.6338	47.9969	20878.9958	43377.1935	8.5625	0.9352
T2	Ameaça	0.6367	47.9931	20901.1614	44542.5883	7.9605	0.9346
T3	Info	0.6260	48.0300	20882.6636	43903.0189	8.1142	0.9347
T4	Info&Ameaça	0.6335	48.0051	20879.6138	43319.4736	8.3540	0.9352
T5	Moral	0.6251	47.9982	20888.4584	44301.3718	8.4832	0.9343
T6	Moral&Ameaça	0.6422	47.9904	20876.3062	43610.1972	8.0468	0.9343
Anova:	p-values	0.1715	0.3993	0.9393	0.7577	0.5795	0.8614

# Análise Exploratória

- Atrito pode quebrar o balanceamento e comprometer a aleatorização

Tratamento	Gênero	Idade	Renda	População	Dens. pop.	Compliance
T0	0.6458	48.0170	20928.4068	45815.2715	8.1711	0.9355
T1	0.6403	47.7868	21100.3921	52084.9822	7.6001	0.9322
T2	0.6211	47.7127	21106.0117	48882.0302	6.5860	0.9337
T3	0.6138	47.8580	21077.8894	51027.8338	6.6317	0.9313
T4	0.6240	47.8056	20945.2352	48251.5259	6.5957	0.9318
T5	0.6177	47.7952	20864.3756	43273.7019	6.3919	0.9308
T6	0.6320	47.8117	20966.9995	46539.3467	6.4614	0.9324
Anova p-valor	0.4319	0.0000	0.0095	0.0936	0.0094	0.1122

# Modelos e Resultados

---

# Estimandos Causais

- *Framework* de Resultados potenciais. Observamos apenas um resultado potencial dado um tratamento. **Problema fundamental da inferência causal**

$$Y_i = D_i \cdot Y_i(1) + (1 - D_i) \cdot Y_i(0), \quad D_i \in \{0, 1\}$$

- Estimandos Casuais:

$$ATE = \mathbb{E}[Y_i(1) - Y_i(0)], \quad CATE(x) = \mathbb{E}[Y_i(1) - Y_i(0)|X = x]$$

$$ATT = \mathbb{E}[Y_i(1) - Y_i(0)|D_i = 1], \quad CATT(x) = \mathbb{E}[Y_i(1) - Y_i(0)|X = x, D_i = 1]$$

$$LATE(x) = \frac{\mathbb{E}[Y_i(1, D_i(1)) - Y_i(0, D_i(0))]}{\mathbb{E}[D_i(1) - D_i(0)]}$$

# Hipóteses de Identificação

- SUTVA: **não existe interferência** entre os indivíduos tratados e não tratados. Não pode haver efeitos de transbordamento do tratamento de algum indivíduo para outro que esteja no grupo de controle
- CIA (*unconfoundedness*): **condicionado às características observadas**,  $X_i$ , os resultados potenciais são **independentes** do tratamento  $D_i$ ,  
 $\{Y_i(1), Y_i(0)\} \perp D_i | X_i$

Quando usamos variáveis instrumentais

- Exclusão do instrumento: designação para tratamento **não afeta diretamente** os resultados potenciais
- Relevância do instrumento: designação para o tratamento aumenta a probabilidade de ser tratado.  $\mathbb{E}[D_i(1) - D_i(0)] > 0$

# Modelo ForestDML

- Modelo parcialmente linear. Tratamento  $T$  é exógeno, não é necessária instrumentalização

$$Y = \theta(X) \cdot T + g(X, W) + \epsilon$$

$$\mathbb{E}[\epsilon \mid X, W] = 0$$

$$T = f(X, W) + \eta$$

$$\mathbb{E}[\eta \mid X, W] = 0$$

$$\mathbb{E}[\eta \cdot \epsilon \mid X, W] = 0$$

- Através de **DML** (ortogonalização de Neyman e *cross-fitting*)

$$\hat{\theta}(x) = \underset{\theta}{\operatorname{argmin}} \sum_{i=1}^n K_x(X_i) \cdot \left( Y_i - \hat{q}(X_i, W_i) - \theta \cdot \left( T_i - \hat{f}(X_i, W_i) \right) \right)^2$$

- Kernel  $K_x$  é uma **floresta causal**



- Tratamento é endógeno. Necessita de variável instrumental

$$Y = \theta(X) \cdot T + g(X) + \epsilon, \quad \mathbb{E}[\epsilon \mid X, Z] = 0$$

$$Z = m(X) + \eta, \quad \mathbb{E}[\eta \mid X] = 0$$

$$\mathbb{E}[\eta \cdot \epsilon \mid X, Z] = 0$$

$$\mathbb{E}[T \cdot \epsilon \mid X] \neq 0$$

- Estimativa preliminar de  $\theta(x)$  e algoritmo *Doubly Robust*

$$\hat{\theta}_{DR}(x) = \operatorname{argmin}_{\theta} \sum_{i \in \mathcal{I}} \left( \theta_{\text{pre}}(x) + \frac{\left( \hat{Y}_i - \theta_{\text{pre}}(x) \hat{T}_i \right) \hat{Z}_i}{\hat{\beta}(X_i)} - \theta(X_i) \right)^2$$

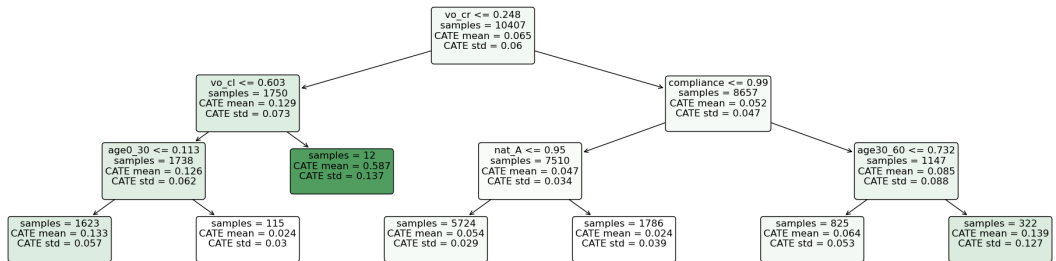
# Resultados

- Receber uma correspondência **tem efeito positivo** sobre o registro para pagamento do tributo
- Uma **ameaça** na carta aumenta este efeito
- Informações e apelo moral não possui efeito estatisticamente significativo

	OLS ATE	ForestDML ATE	ATT	IV2SLS LATE	DRIV LATE
Correio	0,0650	0,0766	0,0766	0,0767	0,0588
<b>Ameaça</b>	<b>0,0750</b>	<b>0,0850</b>	<b>0,0848</b>	<b>0,0872</b>	<b>0,0650</b>
Info	0,0646	0,0762	0,0760	0,0728	0,0547
Moral	0,0648	0,0695	0,0695	0,0724	0,0513

# Efeitos Heterogêneos

- Existem características que moderam o efeito causal?
- Heterogeneidade: efeito causal depende de características individuais
- Regressão linear
  - Simples estimação e interpretação
  - Hipótese a priori das características
- *Machine Learning*
  - descobre a heterogeneidade presente nos dados
  - modelos mais complexos
- Árvores de decisão são um bom compromisso. Aliam interpretabilidade com algoritmo *data-driven*



## Conclusão

---

# Conclusão

- Árvores de decisão são de fácil interpretação. Conjunto de regras
- Fornece informação sobre as características mais relevantes para detectar efeitos heterogêneos
- Os métodos de DML e Causal Forests estimam efeitos livres de viés, heterogêneos e não-paramétricos
- Com base nestas estimações, uma **política ótima** de tratamento pode ser implementada, focando nos indivíduos com maior potencial de resposta

- Chernozhukov, Victor, Denis Chetverikov, Mert Demirer, Esther Duflo, Christian Hansen, Whitney Newey, and James Robins. 2018. “Double/debiased machine learning for treatment and structural parameters.” *The Econometrics Journal* 21 (1): C1–68. <https://doi.org/10.1111/ectj.12097>.
- Fellner, Gerlinde, Rupert Sausgruber, and Christian Traxler. 2013. “Testing Enforcement Strategies in the Field: Threat, Moral Appeal and Social Information.” *Journal of the European Economic Association* 11 (3): 634–60.
- Syrgkanis, Vasilis, Victor Lei, Miruna Oprescu, Maggie Hei, Keith Battocchi, and Greg Lewis. 2019. “Machine Learning Estimation of Heterogeneous Treatment Effects with Instruments.” <http://arxiv.org/abs/1905.10176>.
- Wager, Stefan, and Susan Athey. 2018. “Estimation and Inference of Heterogeneous Treatment Effects Using Random Forests.” *Journal of the American Statistical Association* 113 (523): 1228–42.